



SISTEMA DE CLASIFICACIÓN DE IMÁGENES DE LUNARES UTILIZANDO VISIÓN ARTIFICIAL

Francisco Andres Reales Castro

Pontificia Universidad Javeriana
Facultad de Ingeniería
Departamento de Ingeniería Electrónica
Bogotá D.C
2017

SISTEMA DE CLASIFICACIÓN DE IMÁGENES DE LUNARES UTILIZANDO VISIÓN ARTIFICIAL

Francisco Andres Reales Castro

Trabajo de grado presentado como requisito parcial para optar por el título de:
Ingeniero Electrónico

Director:

Ing. Jairo Alberto Hurtado Londoño. Ph.D

Pontificia Universidad Javeriana
Facultad de Ingeniería
Departamento de Ingeniería Electrónica
Bogotá D.C
2017

Advertencia

“La Universidad Javeriana no se hace responsable de los conceptos emitidos por sus alumnos en sus trabajos de tesis. Solo velará porque no se publique nada contrario al dogma y a la moral católica, porque la tesis no contenga ataques o polémicas puramente personales; antes bien se vea en ella el anhelo de buscar la verdad y la justicia”.

Reglamento de la Pontificia Universidad Javeriana, Artículo 23, de la Resolución 13, de Julio de 1965

Dedicatoria

A mi madre, tíos y abuela.

Agradecimientos

A mi madre por darme la oportunidad de estar aquí, haciendo su mayor esfuerzo para ayudarme con lo que pudiera para cumplir mis sueños y a mis tíos por acogerme, aunque no tuvieran la obligación, y apoyarme en todo momento.

A mi director Jairo Hurtado por creer que podíamos hacer algo grande al aceptar mi propuesta.

Índice

1 Introducción	1
2 Marco teórico	3
2.1 Conceptos básicos de dermatología	
2.1.1 Melanoma.....	3
2.1.2 Procedimientos dermatológicos para el diagnóstico del melanoma.....	3
2.2 Conceptos de procesamiento y clasificación de imágenes.....	4
2.2.1 Modelo matemático de una imagen.....	4
2.2.2 Espacios de color.....	4
2.2.3 Convolución y filtrado de imágenes.....	4
2.2.4 Aprendizaje y clasificación.....	5
3 Objetivos del trabajo de grado	8
3.1 Objetivo general.....	8
3.2 Objetivos específicos.....	8
4 Desarrollo	9
4.1 Pre-procesamiento.....	9
4.1.1 Detección de vellos.....	9
4.2 Segmentación.....	12
4.2.1 Atenuación de sombras.....	14
4.3 Extracción de características.....	16
4.3.1 Características basadas en la asimetría.....	16
4.3.2 Características basadas en los bordes.....	20
4.3.3 Características basadas en el color.....	21
4.3.4 Características obtenidas a partir de las diferencias estructurales.....	23
4.4 Clasificación.....	24
4.4.1 Definición de los conjuntos de entrenamiento.....	24
4.4.1 Métodos de clasificación.....	24
4.5 Protocolo de pruebas.....	25
5 Análisis de resultados	26
6 Conclusiones y recomendaciones	29
7 Bibliografía	31
8 Anexos	33

Lista de Figuras

- Figura. 1.1** Diagrama de bloques del sistema.
- Figura. 2.1** Modelo matemático de una imagen digital.
- Figura. 2.2** Modelo en mezcla de gaussianas (GMM).
- Figura. 2.3** Diagrama en bloques del clasificador.
- Figura. 2.4** Clasificación de un SVM.
- Figura. 2.5** Cambio de los datos de R^2 a R^3 .
- Figura. 2.6** Modelo de Red neuronal de una sola capa.
- Figura. 2.7** Modelo de Red neuronal multi-capa.
- Figura. 2.8** Clasificación utilizando KNN.
- Figura. 4.1** Modelo ideal de vello
- Figura. 4.2** Función gaussiana y su derivada
- Figura. 4.3** Convolución del modelo de vello y la derivada de la gaussiana
- Figura. 4.4** Función Gaussiana
- Figura. 4.5** Función DOG rotada 90°
- Figura. 4.6** Rotaciones de la función DOG
- Figura. 4.7** Resultado de la convolución y suma.
- Figura. 4.8** Resultado de la detección de vellos en el fondo.
- Figura. 4.9** Resultado de la detección de vellos en el fondo por Cristian Ocampo *et al.* [8]
- Figura. 4.10** Lunar, Diagrama de dispersión de color y modelo de mezcla de gaussianas. [8]
- Figura. 4.11** Distribución para un solo canal RGB.
- Figura. 4.12** Resultado mezcla de gaussianas
- Figura. 4.13** Mala segmentación del lunar a causa de las sombras.
- Figura. 4.14** Toma de muestras para la interpolación.
- Figura. 4.15** Grafica del polinomio cuadrático, componente V del espacio HSV e iluminación del polinomio.
- Figura. 4.16** Imagen original, Imagen pre-procesada y segmentación de la nueva imagen por GMM.
- Figura. 4.17** Objeto de mayor área, con llenado de puntos negros, dilatado y lunar segmentado.
- Figura. 4.18** Parámetros geométricos del lunar segmentado, Convex Hull, Bounding Box y elipse ajustada.
- Figura. 4.19** Bounding Box, Elipse ajustada y Convex Hull.
- Figura. 4.20** (a) Imagen original, (b) Variación de textura, (c) Oscuridad de la piel, (d) Información de color.
- Figura. 4.21** Borde del lunar como la resta de la máscara dilatada y original.
- Figura. 4.22** Bordes y gradiente para I_1^N, I_2^N e I_3^N .
- Figura. 4.23** (a) $|I^c - B|$, (b) $|I^c - R|$, (c) $|I^c - CC|$, (d) $|I^c - CO|$, (e) $|I^c - GA|$, (f) $|I^c - N|$ para la Figura. 4.17 – (d)
- Figura. 4.24** Fracciones obtenidas a partir del canal de información de color.
- Figura. 4.25** Histograma de la primera característica y la misma característica al adicionar ruido Gaussiano.
- Figura. 4.26** Obtención de datos de prueba para cada iteración. [9]
- Figura. 4.27** Esquema de obtención de los parámetros desempeño utilizando Cross-Validation. [9]
- Figura. 4.28** Error de entrenamiento (rojo) y de prueba(azul) en función de la cantidad de vecinos (k).
- Figura. 4.29** Lunar más difícil de clasificar (benigno).

1 Introducción

Las condiciones climatológicas actuales, como el calentamiento global, hacen que pueda haber una excesiva exposición solar la cual fomenta la aparición de desórdenes y enfermedades de la piel. Cuando se expone un lunar por un tiempo prolongado a radiación solar, se puede volver cáncer, aumentando su diámetro, cambiando su color y simetría [6]. En la mayoría de los casos, si se consulta a un especialista por una lesión cutánea que tiene una probabilidad alta de volverse cáncer de tipo melanoma¹, se da un lapso de tres a seis meses para observar el comportamiento de la lesión. Sin embargo, en este periodo de tiempo no se tiene acceso frecuente a un especialista, así que, si la lesión llega a volverse maligna antes de la fecha acordada para su revisión, se puede poner en riesgo al paciente.

Cuando se da este periodo de tiempo para observar la evolución de dicha lesión, el médico no tiene acceso al paciente hasta la siguiente revisión. Sin embargo, se puede utilizar una herramienta de control que detecte si la lesión ha tenido cambios significativos e ir de inmediato con el especialista, ya que, si se diagnostica de manera temprana, se tiene un 95% de posibilidad de sobrevivir a este tipo de cáncer [1].

El cáncer de piel de tipo melanoma está entre los tipos de cáncer más peligrosos [6], y es causa de la gran mayoría de las muertes por cáncer de piel [6]. Aproximadamente el 11,2% de las personas que son diagnosticadas con melanoma mueren [6]. Por un lado, en Estados Unidos, es el sexto cáncer más común y es la causa de la mayoría de las muertes en mujeres de entre los 25 y 30 años [6]. Por el otro lado, en Colombia, se presentan alrededor de 1203 casos anualmente con una tasa de mortalidad del 19.9% [7].

El propósito de los métodos propuestos no es reemplazar al experto. Por lo contrario, se ofrece una herramienta de control, a partir de imágenes, que detecte si la lesión ha tenido cambios significativos mientras el médico no tiene acceso al paciente, ayudando a establecer un control adecuado por parte del especialista. Con base en lo anterior, el objetivo general de este trabajo de grado es diseñar y evaluar un sistema de clasificación de imágenes macroscópicas de lunares que requieran seguimiento dermatológico prioritario.




Figura. 1.1 Diagrama de bloques del sistema.

La implementación del sistema se hizo en su totalidad en el lenguaje de programación Python utilizando OpenCV. Sin embargo, las gráficas fueron obtenidas a partir de Matlab. Por otro lado, para esta implementación se generó una base de datos de imágenes de lesiones cutáneas macroscópicas reales con muestras de los dos tipos de lesiones, malignas y benignas, para su posterior aprendizaje y evaluación (esta base de datos fue la utilizada también por Cavalcanti *et al.* [2] y Alcon *et al.* [1]). Para esto, se contaron con 170 muestras (104 benignas y 66 malignas). En la Figura.1.1, se muestra el diagrama de bloques del sistema propuesto en este trabajo de grado, donde a partir de una imagen de una lesión cutánea a través del pre-procesamiento, se reduce el efecto de las sombras del fondo para obtener una imagen uniforme, ya que esto puede afectar la clasificación posteriormente, y se intentan eliminar los vellos, con resultado poco satisfactorios.

¹ Tipo más serio de cáncer de piel, se da cuando los melanocitos (Células que producen melanina) crecen de forma descontrolada [6].

Una vez pre-procesada la imagen; se segmenta el lunar, esto quiere decir que se detecta el lunar en la imagen aislando el fondo. Este proceso se muestra en la Figura. 4.17 - d se obtienen las características, en este caso 70, siendo cada una un modelo matemático de la naturaleza y condición del lunar en la imagen y son necesarias para utilizar los algoritmos de clasificación. Estas características son obtenidas a partir del criterio del ABCD, el cual es un criterio basado en la geometría y color de imágenes estáticas de lesiones macroscópicas, se hablará en detalle sobre este método más adelante. El sistema de clasificación está basado en un algoritmo, el cual minimiza una función de costo la cual depende del tipo de clasificador. Por consiguiente, esto hace que el error en la clasificación sea mínimo. Por otro lado, se entrenan varios sistemas de clasificación para compararlos y seleccionar el que tenga mejores resultados, utilizando una base de datos generada a partir de las características obtenidas, este clasificador es elegido para implementarse con el sistema. Por último, esta clasificación se da a modo de sugerencia para visitar o no a un especialista.

Anteriormente se han propuesto sistemas orientados al diagnóstico automático del cáncer de piel de tipo melanoma, usualmente contando con un pre-procesamiento, segmentación, extracción de características y una clasificación. Una de las ultimas aproximaciones se hizo en 2011. Este procedimiento fue presentado por Cavalcanti *et al.* (*Universidade Federal do Rio Grande do Sul*), en el cual las sombras de la imagen fueron estimadas ajustando un polinomio cuadrático en la piel que no hace parte de la lesión y su efecto fue atenuado removiendo este plano de la imagen. Luego se utilizaron 52 características basadas en el criterio del ABCD (Asimetría, Bordes, Color, Diferencias estructurales), para utilizar un clasificador de k vecinos cercanos (KNN) [2]. En 2013, Cavalcanti *et al.* introduce 12 nuevas características basadas en los valores de la eumelanina y feomelanina² de la lesión y las añade a las características usadas en estudios previos obteniendo una sensibilidad de 99.7%, especificidad del 96.18% y efectividad del 98.66%. Este documento está basado en la primera aproximación (Cavalcanti *et al.* 2011) y mejora los resultados de la misma al añadir nuevas características y modificar las propuestas.

² Forma de melanina, siendo oscura y clara respectivamente [6].

2 Marco teórico

En el presente trabajo se propone un algoritmo para la detección de patrones malignos en un lunar. Para esto, se hace uso de los conceptos propios de la dermatología para detección de este tipo de cáncer. Además, se utilizan métodos propios de la ingeniería como el procesamiento de imágenes y el aprendizaje supervisado para obtener una clasificación final. En esta sección se explican los conceptos técnicos utilizados posteriormente en el desarrollo del trabajo de grado, tanto los conceptos básicos de dermatología como de procesamiento y clasificación de imágenes.

2.1 Conceptos básicos de dermatología

2.1.1 Melanoma

Dentro de las lesiones cutáneas se encuentran las lesiones comunes, como los Nevus Melanocíticos (Lunares comunes adquiridos), y el Melanoma. Este último es provocado por la formación de un tejido maligno con un comportamiento biológico particularmente agresivo, al punto de constituir una de las principales causas de muerte por enfermedad cutánea. [13]

Este tipo de cáncer de piel se caracteriza por ser una enfermedad silenciosa, se puede adquirir este tipo de lesión sin notar la evolución de la enfermedad y puede llegar a un punto donde al momento de detectarla sea imposible de combatirla [8]; ya que este es usualmente indoloro y se revela con la generación de un tumor luego del crecimiento descontrolado de las células de la piel. En sus primeras etapas se puede tratar mediante una serie de procedimientos quirúrgicos en los que retiran la lesión de la región afectada. [13]

Para identificar la presencia de melanoma se inspeccionan patrones específicos sobre la lesión cutánea que sugiere la atención del especialista. También, se puede diagnosticar a partir del tejido maligno luego de ser extraído por medios quirúrgicos de la región afectada (biopsia) [8]. Para el diagnóstico del Melanoma se suelen utilizar dos medidores que dan información de la confiabilidad del diagnóstico; la sensibilidad y especificidad.

- Sensibilidad: Porcentaje de lesiones malignas correctamente diagnosticadas de un conjunto de muestras tomadas.

- Especificidad: Porcentaje de lesiones benignas correctamente diagnosticadas de un conjunto de muestras tomadas.

2.1.2 Procedimientos dermatológicos para el diagnóstico del melanoma

Con base en la frecuencia de aparición de determinadas estructuras en las lesiones melanocíticas se concluye que los patrones estrechamente asociados a patologías melanocíticas dañinas son: Retículo pigmentado (textura en el lunar) prominente o atípico, puntos y glóbulos irregulares, color azul-gris o azul-blanquecino y estructuras vasculares.

Uno de los métodos más utilizados es el método del ABCD cuyo acrónimo se refiere a los cuatro criterios utilizados en el diagnóstico clínico. Estos son: Asimetría, Bordes, Color y Diferencias estructurales. Estos parámetros pueden ser utilizados para representar lesiones malignas y benignas. [14]

Asimetría (A): Es generado por el crecimiento descontrolado de la lesión, debido a mayores concentraciones en diferentes regiones la lesión tiende a poseer una forma irregular.

Bordes (B): Las lesiones melanocíticas poseen bordes pronunciados en sus extremos. Por lo contrario, las lesiones benignas suelen tener bordes que se desvanecen suavemente.

Color (C): Se relaciona con el exceso de melanina bajo la superficie de la lesión, provocando un color diferente sobre una región específica.

Diferencias Estructurales (D): Se refiere a la generación de huecos, puntos, glóbulos y ausencia de homogeneidad (textura) que indica que hay mayor cantidad de melanina en esa región.

2.2 Conceptos de procesamiento y clasificación de Imágenes

2.2.1 Modelo matemático de una imagen

Una imagen se puede ver como una función de dos variables discretas donde a cada coordenada espacial (fila y columna), también denominado pixel, se le asigna un color que se va a representar a partir de un vector de tres componentes, $(x, y) \xrightarrow{f} f(x, y) \in R^3$.




Figura. 2.1 Modelo matemático de una imagen digital.

2.2.2 Espacios de color

Para modelar el color se utiliza un vector donde cada componente da información de la imagen y dicha información depende del espacio en el que esté la imagen. Existen dos espacios especialmente útiles para este trabajo explicados a continuación.

- Espacio de color RGB: El color es representado como una combinación lineal de tres componentes (R: Red (rojo), G: Green (verde) y B: Blue (azul)). Cada componente o canal tiene 8 bits (1 byte), haciendo que el valor vaya de 0 a 255 y en total cada pixel tendrá 24 bits (3 bytes).
- Espacio de color HSV: El color es representado por medio de tres características (H: Hue (tono), S: Saturación (saturación) y V: Value (valor)).

2.2.3 Convolución y filtrado de imágenes

- Convolución: Es una operación matemática que transforma dos imágenes de una sola componente $f(x, y)$ y $h(x, y)$ en una tercera función $g(x, y) = f(x, y) * h(x, y)$ y se calcula a partir de la ecuación (2.1) de esta sección.

$$g(u, v) = \sum_{x=0}^m \sum_{y=0}^n f(u-x, v-y)h(x, y) \quad (2.1)$$

La convolución se utiliza para hacerle transformaciones a las imágenes, hallando la función $h(x, y)$ (respuesta impulso) que produzca la imagen deseada, a este proceso se le llama filtrado y es utilizado en este trabajo para eliminar ruido a partir de una respuesta impulso que calcule un promedio o detectar bordes en la imagen a partir del operador de sobel que es una aproximación discreta al gradiente de un campo escalar.

2.2.4 Aprendizaje y clasificación

- **Aprendizaje automático:** se trata de crear programas capaces de generalizar comportamientos a partir de una información suministrada en forma de muestras. Los dos tipos de Aprendizaje utilizados en este trabajo son el no supervisado y supervisado. [11]

- **Aprendizaje no supervisado:** Se cuenta con un conjunto de muestras siendo estos la entrada al sistema. El sistema no tiene información sobre las categorías de esos ejemplos. Por lo tanto, el sistema tiene que reconocer los patrones presentados en las muestras y clasificar las nuevas entradas. [11]

El algoritmo de aprendizaje no supervisado utilizado fue el Modelo de Mezcla de Gaussianas (GMM) el cual representa la presencia de categorías en las muestras suponiendo que cada categoría tiene una distribución normal, entonces, la distribución de los datos es la superposición de múltiples funciones gaussianas. En la Figura. 2.2 se representa una distribución a partir de dos gaussianas.




Figura. 2.2 Modelo en mezcla de gaussianas (GMM).

- **Aprendizaje supervisado:** Es una técnica para predecir una categoría en un grupo de datos a partir de un previo entrenamiento. Los datos de entrenamiento consisten en las muestras, modeladas como vectores y las etiquetas que son los resultados deseados para cada muestra. El objetivo de este tipo de aprendizaje es crear un algoritmo capaz de predecir el valor de una muestra de entrada después de que le hayan enseñado utilizando un grupo de muestras de entrenamiento. Los algoritmos de aprendizaje supervisado se llaman clasificadores. [11]
- **Clasificación:** Cada clasificador implementado es un sistema que toma un vector de características obtenidas a partir de la imagen y regresa un valor de -1 o 1 que indica la categoría a la que pertenece esa muestra. El diagrama un clasificador se muestra en la Figura. 2.3. Lo que varía en cada topología de clasificador es la función de hipótesis, que es una función que retorna un numero en el intervalo [-1,1] donde se optimiza una función de costo para que el error en la clasificación sea mínimo. Los clasificadores utilizados para el trabajo se explican a continuación.




Figura. 2.3 Diagrama en bloques del clasificador.

- **SVM (Máquina de vectores de soporte):** Si se grafican los datos, en caso de ser posible, este tipo de clasificador normaliza los datos para que las dos muestras más cercanas al hiperplano que separa las dos clases quede a una distancia de 1. Esta distancia entre las dos muestras más

cercanas se le llama el margen y las dos muestras se llaman vectores de soporte. La clasificación optima (error mínimo en la clasificación) se obtiene cuando este margen sea máximo, entonces, si el margen es $\text{Margin} = \frac{2}{\|W\|}$ siendo W el vector normal al hiperplano, se minimiza W . esta idea se muestra en la Figura. 2.4. [9]




Figura. 2.4 Clasificación de un SVM.

Cuando los datos no son linealmente separables, se utiliza la técnica del Kernel, donde se llevan los datos a una dimensión n (Kernel de grado n) donde sean linealmente separables por un hiperplano y se calcula la clasificación en esa dimensión. Lo anterior se muestra la Figura. 2.5 donde se pasan los datos de R^2 a R^3 para así generar una clasificación. [9]




Figura. 2.5 Cambio de los datos de R^2 a R^3 .

- **Red neuronal:** Cada neurona hace una combinación lineal de las componentes del vector y las multiplica por una constante, esta constante se halla para cada neurona tal que minimice el error cuadrático medio utilizando mínimos cuadrados mostrado en la ecuación (2.2) donde el error es la diferencia entre la etiqueta t_i y el resultado del clasificador $y_i(X^{(k)})$. La función de activación escala los datos en el intervalo $(-1,1)$. Esta idea se muestra en la Figura. 2.6. [10]

$$\varepsilon = \frac{1}{2} \sum_i (y_i(X^{(k)}) - t_i)^2 \quad (2.2)$$




Figura. 2.6 Modelo de Red neuronal de una sola capa.

Cuando los datos no son linealmente separables, se deben agregar más capas para que la salida de cada neurona sea la entrada de otra. Haciendo que se pueda generar una clasificación adecuada. Lo anterior se muestra en la Figura. 2.7. [10]




Figura. 2.7 Modelo de Red neuronal multi-capas.

- **Clasificador de *K*-vecinos Cercanos (KNN):** Se calcula la distancia euclidiana entre los vectores almacenados en el entrenamiento y el nuevo vector de entrada, y se seleccionan las *k* muestras más cercanas. La nueva muestra se clasifica con la clase que más se repite en los vectores seleccionados. Este tipo de clasificación se muestra en la Figura 2.8. [9]




Figura. 2.8 Clasificación utilizando KNN.

3 Objetivo del trabajo de grado

3.1 Objetivo general

Diseñar y evaluar un sistema de clasificación de imágenes macroscópicas de lunares que requieran seguimiento dermatológico prioritario.

3.2 Objetivos específicos

1. Obtener y etiquetar cada imagen de la base de datos de los lunares.
2. Diseñar un modelo numérico para cada característica intrínseca de la imagen, basándose en el criterio del ABCD de la dermatología.
3. Entrenar distintos sistemas de clasificación como SVM (máquina de vectores de soporte), red neuronal, y k vecinos cercanos.
4. Evaluar los sistemas de clasificación previamente entrenados.
5. Comparar las medidas de desempeño del sistema de clasificación con los implementados en estudios anteriores.

4 Desarrollo

4.1 Pre-procesamiento

Las imágenes de lesiones cutáneas usualmente tienen otros objetos como pecas o vellos que hacen que la segmentación sea difícil. Las pecas se pueden eliminar tomando el objeto con mayor área de la imagen; y ya que la mayoría de procesos de segmentación lo hacen por color tomando la decoloración de la piel más oscura, los vellos y sombras que son usualmente más oscuros que la lesión, pueden ser confundidos y tomados como parte de esta durante el proceso de segmentación. Para que esto no ocurra, se debe eliminar o atenuar todo tipo de objeto que perturbe la región de interés. El presente trabajo se enfoca en la eliminación de vellos, con resultados poco satisfactorios, y la atenuación de sombras, mostrada en la sesión 4.2.2 de segmentación, ya que pueden afectar de manera negativa la clasificación final.

4.1.1 Detección de vellos

Los objetivos de este paso son, por un lado, eliminar los vellos que están presentes en el lunar, ya que pueden afectar las características de color del lunar haciendo que haya un error en la clasificación, y por el otro, los vellos en la piel no afectada pueden hacer que el sistema de segmentación confunda los vellos con el lunar por su tono oscuro.

Para la detección de vellos, se utiliza la derivada de la función gaussiana por su propiedad de detectar bordes de líneas delgadas, que en este caso son los vellos. Para establecer esta idea, se propone un ejemplo representando la imagen como si fuera una señal de intensidad en función del pixel. En la Figura. 4.1, se puede observar el modelo ideal de vello donde, en la sección transversal, el vello está ubicado en las intensidades más bajas y la piel en las más altas. Si se aplica la convolución entre el modelo de vello y la derivada de la función gaussiana, mostrada en la Figura. 4.2, se obtendrá la Figura. 4.3 y el pico máximo es la ubicación del vello.

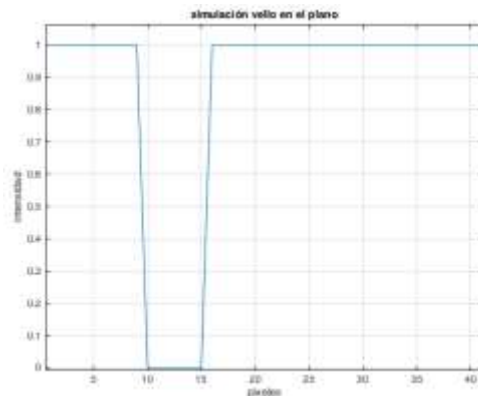


Figura. 4.1 Modelo ideal de vello

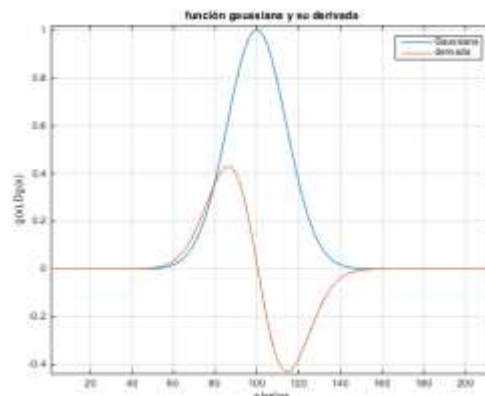


Figura. 4.2 Función gaussiana y su derivada

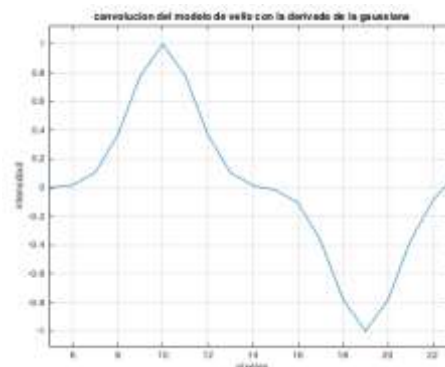


Figura. 4.3 Convolución del modelo de vello y la derivada de la gaussiana

Para la detección de vellos en la imagen se utiliza la misma idea anterior. Sin embargo, teniendo en cuenta que la imagen en escala de grises se puede ver como un campo escalar, se emplea la gaussiana que varía con respecto a x e y , representada por la ecuación (4.1), así, la derivada de la función se obtiene a partir del vector gradiente. Donde Σ es la matriz de covarianza y $X = [x_1, x_2, \dots, x_n]$, que para este caso en particular $X = [x, y]$ que son las coordenadas de los pixeles de la imagen.

$$f_X(x_1, \dots, x_n) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} e^{-\frac{1}{2}(X-\mu)^T \Sigma^{-1} (X-\mu)} \quad (4.1)$$

El operador gradiente da información de los cambios de los vellos de la imagen, dado que los vellos pueden estar orientados de distinta manera, se rota el gradiente determinado ángulo para detectar los vellos en las distintas direcciones. La gaussiana de la ecuación (4.1) se muestra en la Figura. 4.4 y la función DOG en la Figura. 4.5; también, las rotaciones se muestran en la Figura. 4.6. Donde se escogieron cuatro rotaciones para la función DOG, 0° , 45° , 90° y 135° .

El gradiente de la función está dado por la ecuación (4.2).

$$\nabla f_X = \left[\frac{\partial f_X}{\partial x}, \frac{\partial f_X}{\partial y} \right] \quad (4.2)$$

Y el campo escalar rotado, que sirve para hallar los bordes en la dirección θ esta dado por la ecuación (4.3).

$$DOG = \frac{\partial f_X}{\partial x} \cos \theta + \frac{\partial f_X}{\partial y} \sin \theta \quad (4.3)$$

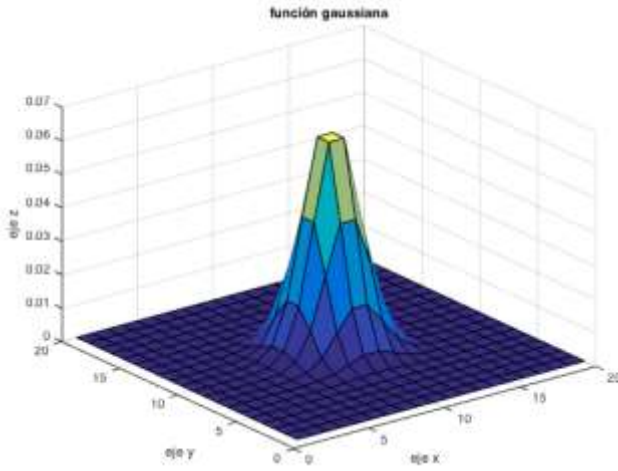


Figura.4. 4: Función Gaussiana

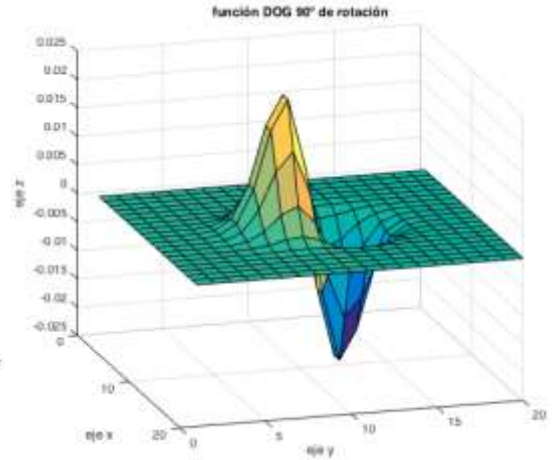


Figura. 4.5: Función DOG rotada 90°




Figura. 4.6: Rotaciones de la función DOG

Por último, se hace la convolución con cada mascara rotada presentada en la Figura. 4.6 y se suman las imágenes obtenidas, pixel a pixel; esto se muestra en la Figura. 4.7.




Figura.4.7: resultado de la convolución y suma.

Como se puede ver en la Figura. 4.8, además de detectar los vellos, el sistema de reconocimiento, confunde algunos bordes del lunar con vellos. Entonces, se puede concluir que hay poca detección de los vellos dentro del lunar, por lo contrario, se detectan características propias de este; en la Figura. 4.8 se muestra la detección en superficie blanca.




Figura.4.8: resultado de la detección de vellos en el fondo.



Figura.4.9: resultado de la detección de vellos en el fondo por Cristian Ocampo *et al.*

En conclusión, contrario a los resultados que Cristian Ocampo *et al.* obtuvo, mostrados en la Figura. 4.9, la detección de vellos implementada en el presente trabajo utilizando la función DOG no fue efectiva. Por un lado, no detectó los vellos presentes en la lesión, y por el otro, no detectó de manera adecuada los vellos del fondo para su posterior eliminación, por lo contrario, en los resultados se observan los cambios pronunciados de la lesión; por esta razón, se propone que el usuario se depile antes del uso de la aplicación con el propósito de alcanzar mayor efectividad en el funcionamiento de la aplicación.

4.2 Segmentación

El propósito de este paso es detectar el lunar en la imagen de forma automática a partir del color. Debido a que las imágenes de lesiones cutáneas tienen colores cercanos a dos grupos, claro y oscuro, que equivale al fondo y al lunar respectivamente, la mezcla de gaussianas (GMM) puede describir de forma adecuada su distribución. Por otro lado, GMM es el método recomendado por Cristian Ocampo *et al.* quien comparó distintas posibilidades para la segmentación.




Figura. 4.10: Lunar, Diagrama de dispersión de color y modelo de mezcla de gaussianas.

En la Figura. 4.10 se muestra el diagrama de dispersión de color, en el cual se pueden separar en dos clases que se representan por dos gaussianas; una con media más cercana a cero y la otra con media más alejada del origen. Para este trabajo se utilizan tres gaussianas, ya que puede haber otros colores en la piel; en caso en que no los haya, la tercera gaussiana tendría un peso muy pequeño y no afectaría la segmentación.

Al obtener la distribución de la imagen como tres gaussianas, se puede evaluar la probabilidad de que determinado pixel pertenezca a alguna de las tres clases, ganando la que tenga mayor probabilidad, esta idea se muestra, a modo de ejemplo, en la Figura. 4.11. Para este caso, el pixel 54 presenta mayor probabilidad de pertenecer a la gaussiana de la mitad, lo que significa que hace parte de la clase 2.

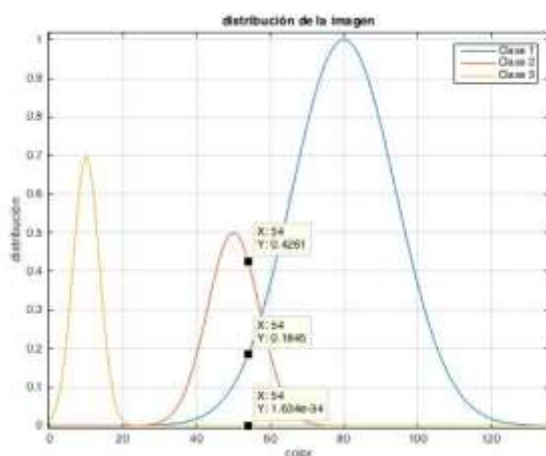


Figura. 4.11: Distribución para un solo canal RGB.

Para poder visualizar la clase a la que pertenece cada pixel, se deja el color del pixel como la media de la clase a la que pertenece. Ya que hay tres clases habrá cuatro colores diferentes. Esto se muestra en la Figura. 4.12.



Figura.4.12: Resultado mezcla de gaussianas

El color más oscuro del resultado de la mezcla de gaussianas se pone de blanco y lo demás de negro, obteniendo la máscara, que da información de la ubicación y forma del lunar. Sin embargo, cuando hay sombras, producidas por la circularidad del cuerpo humano, el sistema se puede confundir y ponerlas como si fuera parte del lunar, como se ve en la Figura. 4.13.



Figura.4.13: Mala segmentación del lunar a causa de las sombras.

Para resolver este problema, se implementa la solución propuesta por Cavalcanti *et al.*, donde se corrigen las sombras de la piel aproximando una función cuadrática que imita el comportamiento de las sombras en la imagen para luego suprimirlas. La idea anterior se explica a continuación.

4.2.1 Atenuación de sombras

Para el uso de este método de atenuación de sombras, se cuenta con dos supuestos. Que las sombras cambian de forma suave en la imagen y que el lunar se ubica en el centro de la misma. Con el primer supuesto, se asegura que un polinomio de grado dos se acomodará de forma adecuada a las sombras. El segundo supuesto asegura que se puedan tomar muestras en las esquinas de la imagen sin tocar el lunar, muestras que se utilizan posteriormente en la interpolación.

Los datos tomados para la interpolación son obtenidos a partir del canal 'V' del espacio de color HSV, donde se toman muestras de las esquinas, como un porcentaje de las filas y columnas del 30%, esto hace que las muestras tomadas dependan del tamaño de la imagen. Contraria a la implementación de Cavalcanti *et al.*, donde utilizan en cada esquina un cuadro de muestras de 20x20 pixeles, haciendo que este fuera constante para cualquier imagen. Así que el sistema propuesto por Cavalcanti *et al.* tendría un problema con imágenes muy grandes o muy pequeñas. La toma de muestras para la interpolación se muestra en la Figura. 4.14.



Figura.4.14: Toma de muestras para la interpolación.

Al tener las muestras de la imagen en las regiones cercanas a los vértices, se sabe el comportamiento de las sombras, así que se procede a hallar el polinomio de grado dos que describa mejor este comportamiento haciendo uso de la técnica de optimización de mínimos cuadrados.

El polinomio de grado dos que se aproxima va a ser de la forma del presentado en la ecuación (4.4).

$$z(x, y) = p_1x^2 + p_2y^2 + p_3xy + p_4x + p_5y + p_6 \quad (4.4)$$

Donde se encontrarán las seis constantes que minimicen el error cuadrático dado por la ecuación (4.5).

$$\mathcal{E} = \sum_{j \in S} \sum_{i \in S} [V(j, i) - z(x_j, y_i)]^2 \quad (4.5)$$

Donde i, j son los índices del conjunto de muestras de las esquinas 'S'; Figura. 4.14., V es el valor del canal V del espacio HSV y Z la función cuadrática que se va a hallar.

Después de obtener las constantes que minimizan el error, se obtiene el siguiente resultado para la imagen de la Figura. 4.14, mostrada en la Figura.4.15.




Figura.4.15: Grafica del polinomio cuadrático, componente V del espacio HSV e iluminación del polinomio.

Ya que se tiene el polinomio cuadrático que se acomoda a las sombras de la imagen, se atenúan las sombras dividiendo la componente V del espacio HSV obtenido anteriormente entre el polinomio cuadrático hallado, como se muestra en la ecuación (4.6).

$$V_{proc}(x, y) = \frac{V(x, y)}{z(x, y)} \quad (4.6)$$

Sin embargo, como la ecuación mostrada en la ecuación (4.6) es una versión normalizada, se tiene que multiplicar por una constante para que su brillo no se vea afectado, obteniendo la ecuación (4.7).

$$V_{nuevo}(x, y) = \frac{\mu_V}{\mu_{proc}} V_{proc}(x, y) \quad (4.7)$$

Donde $V_{nuevo}(x, y)$ será el nuevo canal V, que se cambiará en la imagen original, $V_{proc}(x, y)$ será la versión normalizada de $V(x, y)$ cuyas sombras fueron filtradas, μ_V es la media de $V(x, y)$ y μ_{proc} la media de la versión procesada.

Por último, después de haber cambiado el canal V por el procesado, hallado anteriormente, se pasa al espacio de color RGB y se prueba de nuevo la segmentación por mezcla de gaussianas.

En la Figura.4.16 se observa que después de la atenuación de sombras, ya se puede segmentar el lunar de manera adecuada, contrario a lo que pasaba en la Figura. 4.13.



Figura.4.16: Imagen original, Imagen pre-procesada y segmentación de la nueva imagen por GMM.

Para finalizar la segmentación, se calculará el área de cada objeto en la imagen binarizada por mezcla de gaussianas y solo se dejará el objeto que tenga mayor área. También, se eliminarán los puntos negros en este objeto y, por último, se utilizará la operación morfológica de dilatación para suavizar los bordes y recuperar bordes difusos.




Figura.4.17: Objeto de mayor área, con llenado de puntos negros, dilatado y lunar segmentado.

4.3 Extracción de características

Para la caracterización del lunar, se escogió el criterio del ABCD por la posibilidad de medir sus parámetros usando la información contenida en imágenes de lesiones cutáneas macroscópicas.

4.3.1 Características basadas en la asimetría

Las características de asimetría se obtienen a partir de la máscara mostrada en la Figura.4.17 (c). Para esto, en la Tabla 1., se definen estas características que dan información de la asimetría de la lesión y los parámetros medidos se pueden observar gráficamente en la Figura. 4.18 que fueron obtenidos a partir de la geometría del lunar segmentado; en negro, casco convexo (*Convex Hull*); en azul punteado, rectángulo delimitador (*Bounding Box*); en rojo y la elipse ajustada, en magenta. Para hallar los ejes b_p y a_p se utilizan los vectores propios que dan información de la orientación del lunar.




Figura.4.18: Parámetros geométricos del lunar segmentado, casco convexo, Rectángulo delimitador y elipse ajustada.

Nombre	Nomenclatura	Descripción	Unidades	Referencia
Área de la lesión	A_p	Área del objeto, calculado a partir de la máscara de la Figura.4.17.	Área	Alcon <i>et al.</i> [1]
Área del Convex Hull	A_c	Área del casco convexo, calculado a partir de la máscara de la Figura 4.19.	Área	Alcon <i>et al.</i> [1].
Solidez	A_p/A_c	Relación entre el área de la lesión y el área del casco convexo.	Adimensional	Alcon <i>et al.</i> [1]
Diámetro equivalente	$\sqrt{\frac{4A_p}{\pi}}$	Si se sustituyera el área por el de una circunferencia, daría el doble del radio (diámetro).	Longitud	Alcon <i>et al.</i> [1] ³
Circularidad	$\frac{4\pi A_p}{P_p^2}$	Da medida de que tan circular es la lesión, si el área y el perímetro fuesen de circunferencias, este daría '1'.	Adimensional	Alcon <i>et al.</i> [1]
Perímetro de la lesión	P_p	Perímetro de la figura en la máscara, mostrada en la Figura.4.17.	Longitud	Alcon <i>et al.</i> [1]
Relación de forma	b_p/a_p	Relación entre los ejes de la lesión.	Adimensional	Alcon <i>et al.</i> [1]
Perímetro del Convex Hull	P_c	Perímetro del casco convexo .	Longitud	Alcon <i>et al.</i> [1]
Tasa de aspecto	b_b/a_b	Relación entre los lados del rectángulo delimitador.	Adimensional	Alcon <i>et al.</i> [1]
Tasa de área elíptica	A_p/A_e	Da medida del parecido del área de la lesión con el área de la elipse que se ajusta y es la relación entre el área de la lesión y de la elipse.	Adimensional	Propuesta en el presente trabajo
Tasa de perímetro elíptico	P_p/P_e	Da medida del parecido del perímetro de la lesión con el perímetro de la elipse que se ajusta y es la relación entre el perímetro de la lesión y de la elipse.	Adimensional	Propuesta en el presente trabajo
Diferencia de áreas de los extremos del eje b_p normalizada	$(B1 - B2)/A_p$	Relación entre la diferencia de áreas de los extremos cortados por el eje b_p y el área de la lesión.	Adimensional	Cavalcanti <i>et al.</i> [2]
Diferencia de áreas de los extremos del eje a_p normalizada	$(A1 - A2)/A_p$	Relación entre la diferencia de áreas de los extremos cortados por el eje a_p y el área de la lesión.	Adimensional	Cavalcanti <i>et al.</i> [2]
Tasa de forma con respecta a b_p	$B1/B2$	Relación entre el área de cada extremo del eje b_p .	Adimensional	Cavalcanti <i>et al.</i> [2]
Tasa de forma con respecta a a_p	$A1/A2$	Relación entre el área de cada extremo del eje a_p .	Adimensional	Cavalcanti <i>et al.</i> [2]

Tabla 1. Características de asimetría.

Los parámetros son, b_p y a_p ; ejes menor y mayor. A_p , A_c , A_b y A_e ; área de la lesión, Casco convexo, Rectángulo delimitador y elipse respectivamente y P_p , P , A_b y P_e ; perímetro de la lesión, Casco convexo, Rectángulo delimitador y elipse respectivamente

Alcon *et al.* implementó el rectángulo delimitador recto, haciendo que los parámetros de este cambien con la rotación. Para evitar este problema, se utilizó el rectángulo delimitador rotado, ya que este acomodará su ángulo de rotación de forma automática para ajustarse al lunar, haciendo que las características sean independientes de la rotación de la foto. Por otro lado, se añadieron nuevas características dando información del parecido del lunar con una elipse.

³ Se utiliza la característica de diámetro equivalente. Sin embargo, se modifica la fórmula para que solo dependa del área de la máscara.

Como se puede observar en la Tabla 1, hay muchas características que tienen unidades de área y longitud, esto hará que el tamaño y resolución de la imagen tenga un efecto negativo en dichas características. Para que las características no dependan de estos parámetros, se dividirán las que tienen unidades de área entre el área del rectángulo delimitador A_b y las de longitud se dividirán entre su perímetro P_b . De esta forma las características estarán normalizadas y no dependen del tamaño de la imagen, distancia de la cámara a la hora de tomar la foto o resolución.

En la Figura. 4.19 se muestran las figuras geométricas del ejemplo de la Figura. 4.18, de las cuales se obtienen las características de asimetría, pero en este caso para una foto de una lesión cutánea real.




Figura.4.19: Rectángulo delimitador, Elipse ajustada y Casco convexo.

Para las características basadas en los bordes, color y diferencias estructurales se crea una nueva imagen I^N , a partir de la imagen original, la cual tiene tres canales donde el primer canal da información de la variación de la textura, el segundo información de la oscuridad de la piel y el tercero da información del color, $I_i^N (i = 1, 2, 3)$.

Canal de información de la variación de textura (I_1^N)

Primero se obtiene la imagen de luminosidad L , obtenida a partir de la ecuación (4.8), donde se promedian los tres canales de la imagen original I^C .

$$L(x, y) = \frac{\sum_{i=1}^3 I_i^C}{3} \quad (4.8)$$

La textura $\tau(x, y, \sigma)$ se define por la ecuación (4.9) donde $S(x, y, \sigma) = L(x, y) * G(\sigma)$ es la luminosidad suavizada por un filtro gaussiano con varianza σ .

$$\tau(x, y, \sigma) = \frac{L(x, y)}{S(x, y, \sigma)} - L(x, y) \quad (4.9)$$

Ya que S es una versión sin textura de la imagen L , dado que fue suavizada, al dividirse se acercan a uno las partes del lunar que no poseen textura, dejando solo la textura del lunar. Al restarse la imagen L , se obtiene una imagen similar al complemento de la imagen L , pero con la textura incluida.

Para que se pueda capturar la información de textura de la imagen de forma generalizada se calcula la textura $\tau(x, y, \sigma)$ para diferentes valores de σ , $\{\sigma_1, \dots, \sigma_N\}$, y se selecciona para cada pixel el que de mayor textura entre todas las escalas de σ , esto se muestra en la ecuación (4.10). Para este trabajo se escogió una varianza de $\sigma = \left\{1, \frac{11}{7}, \dots, \frac{43}{7}\right\}$ con una ventana de $7 \times 7 \sigma$.

$$\tau(x, y) = \max_{\sigma} [\tau(x, y, \sigma)], \quad \sigma = \{\sigma_1, \dots, \sigma_N\} \quad (4.10)$$

El canal se obtendrá a partir de la normalización de $\tau(x, y)$, mostrada en la ecuación (4.11), donde se le resta el mínimo, y se divide entre la diferencia haciendo que todos los datos estén en el intervalo $[0, 1]$.

$$I_1^N = \frac{\tau(x, y) - \min_{x,y}[\tau(x, y)]}{\max_{x,y}[\tau(x, y)] - \min_{x,y}[\tau(x, y)]} \quad (4.11)$$

El resultado de I_1^N se muestra en la Figura. 4.20 (b).

Canal de información de la oscuridad de la piel (I_2^N)

Ya que la piel saludable tiende a ser rojiza, cuando el canal rojo de la imagen original es más brillante quiere decir que hace parte del fondo y si es más oscuro es la lesión. Así que las sombras están dadas por el complemento del canal rojo de la imagen original, como se muestra en la ecuación (4.12).

$$I_2^N = 1 - I_1^C \quad (4.12)$$

El resultado de I_2^N se muestra en la Figura. 4.20 (c).

Canal de información de color (I_3^N)

Se representa la información de los tres canales de la imagen original I^C en un solo canal I_3^N , para esto se ordena la imagen original en una matriz de $3xp$, siendo $p = mxn$ la cantidad de pixeles en la imagen y 3 la cantidad de canales, después se retira la media de los datos haciendo que la suma sea cero $\sum \vec{C}_i = \vec{0}$ y se define la matriz $B = [\vec{C}_1 | \vec{C}_2 | \dots | \vec{C}_p]$ donde su matriz de covarianza Σ se obtiene a partir de la ecuación (4.13).

$$\Sigma_{3x3} = \frac{1}{p-1} BB^T \quad (4.13)$$

Los elementos que están en la diagonal de la matriz son las varianzas de cada variable y los demás elementos son las covarianzas entre cada par de variables.

Los valores propios $\lambda_1, \lambda_2, \lambda_3$ con $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0$ dan información de la varianza total $T = \lambda_1 + \lambda_2 + \lambda_3$, y λ_1 da el mayor porcentaje de esta varianza. Así que el vector propio \vec{u}_1 , asociado a λ_1 , apunta hacia donde la varianza de los datos es mayor en el espacio RGB.

Por lo anterior, se obtiene la proyección del vector de tres componentes RGB para cada pixel $\vec{C}(x, y)$ a lo largo de la dirección del vector \vec{u}_1 que produce máxima varianza, esta proyección es un escalar que puede tener valores positivos y negativos, dado que es un producto interno, por esta razón se obtiene el valor absoluto $|C_1|$.

Ya que los datos de color $\vec{C}(x, y)$ están centrados alrededor de la media $\vec{\mu}$ y la piel de fondo es más frecuente, la proyección a lo largo de la mayor varianza es muy cercana a cero, así que $|C_1| \approx 0$. Sin embargo, en los pixeles que hacen parte de la lesión esta proyección tiende a ser mayor de cero.

Para obtener el canal de información de color, se normaliza $C(x, y) = |C_1|$ para cada pixel de la imagen como se muestra en la ecuación (4.14).

$$I_3^N = \frac{C(x, y) - \min_{x,y}[C(x, y)]}{\max_{x,y}[C(x, y)] - \min_{x,y}[C(x, y)]} \quad (4.14)$$

El resultado de I_3^N se muestra en la Figura. 4.20 (d).




Figura.4.20: (a) Imagen original, (b) Variación de textura, (c) Oscuridad de la piel, (d) Información de color.

4.3.2 Características basadas en los bordes

Para cuantificar los cambios de los bordes del lunar, se debe evaluar la derivada direccional de la imagen en dirección radial en los bordes, ya que este dice si el cambio es pronunciado o suave.

Primero, el borde se obtiene a partir de la resta entre la máscara dilatada y la original mostradas respectivamente en la Figura. 4.17 (b) y (c). Haciendo que se tome mayor información de los bordes en el lunar. Los bordes para la Figura. 4.17 se observan en la Figura. 4.21.




Figura.4.21: Borde del lunar como la resta de la máscara dilatada y original.

Dado que el vector gradiente apunta a la dirección con mayor rapidez de cambio de la imagen, que en este caso es radial si se está ubicado en el borde \mathbf{B} , la derivada direccional se puede aproximar a partir de la magnitud del vector gradiente, así que si se toma la media y varianza se deben cumplir las aproximaciones de las ecuaciones (4.15) y (4.16).

$$\mu = \frac{1}{N} \sum_{(x,y) \in \mathbf{B}} \frac{\partial I(x,y)}{\partial \vec{r}} \approx \frac{1}{N} \sum_{(x,y) \in \mathbf{B}} |\nabla I(x,y)| \quad (4.15)$$

$$\sigma^2 = \frac{1}{N} \sum_{(x,y) \in \mathbf{B}} \left(\frac{\partial I(x,y)}{\partial \vec{r}} - \mu \right)^2 \approx \frac{1}{N} \sum_{(x,y) \in \mathbf{B}} (|\nabla I(x,y)| - \mu)^2 \quad (4.16)$$

Donde $\frac{\partial I(x,y)}{\partial r}$ es la derivada direccional en dirección \vec{r} y $\nabla I(x,y)$ el gradiente para el campo escalar $I(x,y)$.

Ya que en una imagen de una lesión cutánea la magnitud del vector gradiente depende del color de la piel, haciendo que de menor si el color de piel es más oscuro, se utilizan los canales previamente hallados I_1^N, I_2^N e I_3^N que dependen en menor medida de este parámetro. Para aproximar el gradiente de la imagen se utiliza el operador de Sobel, que se muestra en la Figura.4.22, y muestra el borde del lunar y el gradiente de los tres canales I^N . Con los cuales se calcula la media y varianza para cada canal obteniendo seis características más.




Figura.4.22: Bordes y gradiente para I_1^N, I_2^N e I_3^N .

También se divide el lunar en ocho fragmentos, cuyos ejes principales están orientados en la dirección del lunar, esto se asegura utilizando los vectores propios, y se obtienen el promedio de medias de los gradientes en cada fragmento que pertenece al borde de la lesión y su varianza, así obteniendo dos nuevas características por cada canal. Esta idea es similar a la propuesta en la Figura. 4.24. Sin embargo es utilizada para características de color.

Nombre	Cantidad	Referencia
Media del gradiente para cada canal	3	Cavalcanti <i>et al.</i> [2]
Varianza del gradiente para cada canal	3	Cavalcanti <i>et al.</i> [2]
Promedio de las medias del gradiente para los ocho fragmentos por cada canal.	3	Cavalcanti <i>et al.</i> [2]
Varianza de las medias del gradiente para los ocho fragmentos por cada canal.	3	Cavalcanti <i>et al.</i> [2]

Tabla 2. Características de Bordes.

4.3.3 Características basadas en el color

Las características de color se obtienen a partir de las imágenes de la lesión segmentada, mostrada en la Figura. 4.17 - (d), y la información de variación de color, mostrada en la Figura. 4.20 - (d). Ambas imágenes se suavizan con un filtro gaussiano para eliminar el ruido en el color. También se utiliza la Tabla 3. donde se muestran los tonos de interés, ya que si una lesión contiene estos tonos es más probable que sea maligna. Por esto, se crean seis contadores, que se incrementan dependiendo de la cercanía del color de determinado pixel con los tonos de la Tabla 3., calculándose como la distancia euclidiana, si el color del pixel es más cercano a alguno de los tonos, el respectivo contador del tono se incrementa. Esto se hace con todos los pixeles que pertenecen a la lesión y por último se divide entre el área de la lesión para normalizar. También, se propone en el presente estudio añadir la media y varianza de una nueva imagen obtenida como la distancia euclidiana entre el color de la imagen original para cada pixel y los tonos de interés, estos parámetros dan información de qué tan alejados están los colores de los tonos de interés en promedio y que tanto se alejan de ellos, las imágenes donde se muestran las distancias entre los colores de cada pixel de la imagen y los tonos de interés se muestran en la Figura. 4.23, donde un color claro representa una distancia mayor y un color oscuro una distancia menor.

Color	Rojo	Verde	Azul
Blanco (B)	1	1	1
Rojo (R)	0.8	0.2	0.2
Café claro (CC)	0.6	0.4	0
Café oscuro (CO)	0.2	0	0
Gris azulado (GA)	0.2	0.6	0.6
Negro (N)	0	0	0

Tabla 3. Tonos de interés en lesiones cutáneas.




Figura.4.23: (a) $|I^c - B|$, (b) $|I^c - R|$, (c) $|I^c - CC|$, (d) $|I^c - CO|$, (e) $|I^c - GA|$, (f) $|I^c - N|$ para la Figura. 4.17 – (d)

En el presente trabajo se proponen otras características de color que dependen de la ubicación del color en la imagen. Para esto, se divide el canal de información de color I_3^N en ocho fragmentos, cuyos ejes principales van en la dirección de orientación del lunar, esto se asegura utilizando los vectores propios, y se obtienen el promedio de medias de la intensidad en cada fragmento que pertenece a la lesión y su varianza, así se añaden dos nuevas características. Esta idea se muestra en la Figura. 4.24, donde se pueden observar las diferencias de color en cada fragmento.




Figura.4.24: Fracciones obtenidas a partir del canal de información de color.

Nomenclatura	Descripción	Referencia	Nomenclatura	Descripción	Referencia
$max(R)$	Máximo del canal rojo en la lesión	Alcon <i>et al.</i> [1]	C_{blanco}	Contador de blanco	Alcon <i>et al.</i> [1]
$max(G)$	Máximo del canal verde en la lesión	Alcon <i>et al.</i> [1]	C_{rojo}	Contador de rojo	Alcon <i>et al.</i> [1]
$max(B)$	Máximo del canal azul en la lesión	Alcon <i>et al.</i> [1]	C_{cafeC}	Contador de café claro	Alcon <i>et al.</i> [1]
$min(R)$	Mínimo del canal rojo en la lesión	Alcon <i>et al.</i> [1]	C_{cafeO}	Contador de café oscuro	Alcon <i>et al.</i> [1]
$min(G)$	Mínimo del canal verde en la lesión	Alcon <i>et al.</i> [1]	C_{grisA}	Contador de gris azulado	Alcon <i>et al.</i> [1]
$min(B)$	Mínimo del canal azul en la lesión	Alcon <i>et al.</i> [1]	C_{negro}	Contador de negro	Alcon <i>et al.</i> [1]
$mean(R)$	Media del canal rojo en la lesión	Alcon <i>et al.</i> [1]	$mean(I^c - B)$	Media de la distancia con blanco	Propuesta en el presente trabajo
$mean(G)$	Media del canal verde en la lesión	Alcon <i>et al.</i> [1]	$mean(I^c - R)$	Media de la distancia con rojo	Propuesta en el presente trabajo
$mean(B)$	Media del canal azul en la lesión	Alcon <i>et al.</i> [1]	$mean(I^c - CC)$	Media de la distancia con café claro	Propuesta en el presente trabajo
$var(R)$	Varianza del canal rojo en la lesión	Alcon <i>et al.</i> [1]	$mean(I^c - CO)$	Media de la distancia con café oscuro	Propuesta en el presente trabajo
$var(G)$	Varianza del canal verde en la lesión	Alcon <i>et al.</i> [1]	$mean(I^c - GA)$	Media de la distancia con gris azulado	Propuesta en el presente trabajo
$var(B)$	Varianza del canal azul en la lesión	Alcon <i>et al.</i> [1]	$mean(I^c - N)$	Media de la distancia con negro	Propuesta en el presente trabajo
$max(I_3^N)$	Máximo del canal I_3^N en la lesión	Alcon <i>et al.</i> [1]	$var(I^c - B)$	Varianza de la distancia con blanco	Propuesta en el presente trabajo
$mean(I_3^N)$	Media del canal I_3^N en la lesión	Alcon <i>et al.</i> [1]	$var(I^c - R)$	Varianza de la distancia con rojo	Propuesta en el presente trabajo
$var(I_3^N)$	Varianza del canal I_3^N en la lesión	Alcon <i>et al.</i> [1]	$var(I^c - CC)$	Varianza de la distancia con café claro	Propuesta en el presente trabajo
$mean(R)/mean(G)$	Relación entre las medias del canal rojo y verde	Alcon <i>et al.</i> [1]	$var(I^c - CO)$	Varianza de la distancia con café oscuro	Propuesta en el presente trabajo
$mean(R)/mean(B)$	Relación entre las medias del canal rojo y azul	Alcon <i>et al.</i> [1]	$var(I^c - GA)$	Varianza de la distancia con gris azulado	Propuesta en el presente trabajo
$mean(G)/mean(B)$	Relación entre las medias del canal verde y azul	Alcon <i>et al.</i> [1]	$var(I^c - N)$	Media de la distancia con negro	Propuesta en el presente trabajo
$mean(I_{3,\mu,8}^N)$	Promedio de las ocho medias de las intensidades de cada fragmento	Propuesta en el presente trabajo	$var(I_{3,\mu,8}^N)$	Varianza entre las ocho medias.	Propuesta en el presente trabajo

Tabla 4. Tonos de interés en lesiones cutáneas.

En la Tabla 4., se definen las características que dan información de las variaciones de color. Siendo R, G y B los datos de los canales de la imagen original para los píxeles que hacen parte de la lesión. De la misma forma para I_3^N se toman solo los valores que pertenecen a la lesión.

4.3.4 Características Obtenidas a Partir de Las Diferencias Estructurales

Aunque las diferencias estructurales solo son medibles a partir del dermatoscopio, se pueden medir diferencias entre lunares benignos y malignos usando características basadas en la textura del lunar. Se extraen cuatro características nuevas que son el mínimo, máximo, media y varianza de las intensidades I_1^N que hacen parte de la lesión.

Característica	Descripción	Referencia
$\min(I_1^N)$	Mínimo del canal de textura	Cavalcanti <i>et al.</i> [2]
$\max(I_1^N)$	Máximo del canal de textura	Cavalcanti <i>et al.</i> [2]
$\text{mean}(I_1^N)$	Media del canal de textura	Cavalcanti <i>et al.</i> [2]
$\text{var}(I_1^N)$	Varianza del canal de textura	Cavalcanti <i>et al.</i> [2]

Tabla 5. Características basadas en diferencias estructurales.

Para obtener las características para cada una de las 170 imágenes y generar el conjunto de entrenamiento, el sistema se demoró 2 horas, 53 minutos y 15 segundos, que equivale en promedio a 1 minuto para una imagen promedio de 238x238.

4.4 Clasificación

A partir de las 70 características propuestas para describir el lunar en la imagen, se puede obtener una clasificación que determine si el lunar presentado tiene cáncer o no. Se discute como la información es procesada en las siguientes secciones.

4.4.1 Definición de los conjuntos de entrenamiento

La base de datos inicial es la misma utilizada por Alcon *et al.* la cual cuenta con 66 imágenes de lesiones cutáneas malignas y 104 benignas. Dado que la cantidad de muestras es muy pequeña como para tener datos estadísticos válidos, después de generar las características para cada imagen, se propone adicionar a cada muestra un error Gaussiano con media cero y desviación estándar diez veces más pequeña que la desviación de cada característica. Así, se ampliará la base de datos para obtener resultados validos posteriormente. Cada nueva muestra estará dada por la ecuación (4.17) donde $\vec{Y}_k, \vec{X}_n, \vec{G}_k \in R^{70}$, \vec{G}_k es un vector aleatorio con distribución normal, \vec{Y}_k es la nueva muestra obtenida a partir de adicionar error Gaussiano y \vec{X}_n es la muestra real actual. El histograma de la adición de este error se muestra en la Figura. 4.25.

$$\vec{Y}_k = \vec{X}_n + \vec{G}_k \quad (4.17)$$

Utilizando lo anterior, se obtiene una base de datos ampliada de 198 muestras malignas y 208 benignas. Además, se descarta la idea utilizar PCA⁴ (Análisis de componentes principales) para reducción de dimensionalidad, ya que al eliminar características que no parecen importantes para un conjunto dado de entrenamiento, provoca que lesiones malignas puedan ser incorrectamente clasificadas como benignas en otro conjunto.

⁴ Análisis que permite seleccionar las características que dan la mayor cantidad de la varianza de los datos para reducir las dimensiones del vector.




Figura. 4.25. Histograma de la primera característica y la misma característica al adicionar ruido Gaussiano.

4.4.2 Métodos de clasificación

La base de datos ampliada sirve como entrada para el sistema de clasificación, el cual se entrena minimizando una función de costo haciendo que el error en la clasificación sea lo más pequeño posible. Para la clasificación de imágenes de lesiones cutáneas se utiliza de forma usual el clasificador SVM (Máquina de vectores de soporte). Sin embargo, es complicado determinar el kernel que se adapte al tipo de problema. Lo mismo acontece con las redes neuronales al escoger el número de capas. Cavalcanti *et al.* utilizó un clasificador de K- vecinos cercanos con $K=1$ ya que era simple y había sido utilizado de forma exitosa en la clasificación de lesiones cutáneas. En los resultados presentados en la sección 5 se muestra el desempeño de los distintos clasificadores expuestos anteriormente para seleccionar el que tenga mejores resultados.

4.5 Protocolo de pruebas

La validación del sistema requiere la definición de conjuntos de entrenamiento, dos métodos son utilizados de forma usual. El primero se llama validación mantenida (holdout validation) [9], que divide el conjunto de datos de forma aleatoria en dos y se selecciona la mayor parte para entrenamiento y las muestras restantes son utilizadas para probar el sistema con imágenes que nunca ha visto. Sin embargo, en este método las muestras tomadas pueden no ser representativas. El segundo método es validación cruzada (cross-validation) [9], que es utilizada para garantizar que los resultados son independientes de las particiones de entrenamiento y prueba; se utiliza para estimar la precisión de un modelo que se llevara a cabo en la práctica. En el presente trabajo se emplea la validación cruzada aleatoria (random cross-validation), ya que es el método utilizado por estudios anteriores y se puede hacer una comparación adecuada entre los modelos propuestos anteriormente con el presentado; además, es el más adecuado para hacer una comparación entre clasificadores. En la Figura.4.26, se muestra la adquisición de muestras de prueba de forma aleatoria para cada iteración, las restantes serán las de entrenamiento.




Figura. 4.26. Obtención de datos de prueba para cada iteración.

Después, se entrena el sistema con las muestras de entrenamiento para cada iteración y se evalúan los parámetros de desempeño del clasificador. Por último, se calcula el promedio de los parámetros de

desempeño de las muestras de prueba para cada iteración. Esto se muestra en la Figura. 4.27. Para el presente trabajo se hicieron 60 iteraciones.

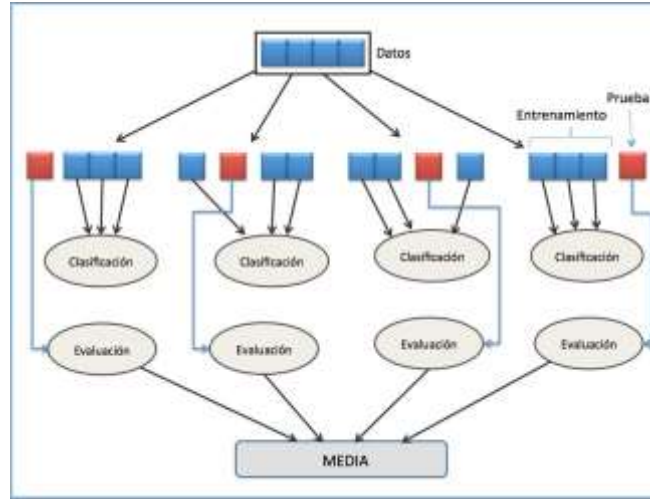


Figura. 4.27. Esquema de obtención de los parámetros de desempeño utilizando validación cruzada.

5 Análisis de Resultados

Ya que conocer el error en la clasificación no es el único parámetro relevante a la hora de validar los sistemas orientados al soporte de diagnóstico médico, se introducen dos nuevos parámetros que dan información de la capacidad del sistema de reconocer lesiones malignas (sensibilidad) y la capacidad de reconocer lesiones benignas (especificidad). Estos parámetros se obtienen a partir de las ecuaciones (5.1) y (5.2).

$$\text{sensibilidad} = 100\% \frac{\text{malignos clasificados como malignos}}{\text{malignos clasificados como malignos} + \text{malignos clasificados como benignos}} \quad (5.1)$$

$$\text{especificidad} = 100\% \frac{\text{benignos clasificados como benignos}}{\text{benignos clasificados como benignos} + \text{benignos clasificados como malignos}} \quad (5.2)$$

La efectividad se calcula a partir de los datos mal clasificados y su complemento es el error en la clasificación. Por otro lado, el complemento de la sensibilidad, es el porcentaje de lesiones malignas que se clasifican como benignas, el cual es uno de los mayores parámetros a tener en cuenta, ya que representaría un riesgo para el usuario, así que se requiere una sensibilidad lo más alta posible. El complemento de la especificidad es el porcentaje de benignos clasificados como malignos, lo cual no representaría ningún riesgo. Cabe aclarar que los parámetros anteriores se calculan a partir de los datos de prueba y la efectividad de entrenamiento es el valor que se optimizó en el clasificador en la etapa de entrenamiento. Los datos de entrenamiento y prueba de la Tabla. 6 se generaron utilizando la base de datos ampliada obtenida en la subsección 4.4.1 y los resultados utilizando la base de datos original se muestran en la Tabla. 7 con los clasificadores entrenados con la base de datos ampliada.

La Tabla. 6 sugiere que el mejor clasificador para este tipo de problema es el clasificador K-vecinos cercanos de $k=1$, lo cual es coherente con lo afirmado por Cavalcanti *et al.* en [2]. El cual utiliza este clasificador porque afirma que ya ha sido utilizado exitosamente en la clasificación de imágenes de lesiones cutáneas. Además, si se aumenta el número de vecinos disminuye la efectividad, ya que, al tomar una porción mayor de muestras, se obtienen más de la clase a la que no pertenece la muestra, generando una comparación errada. Por otro lado, el SVM con kernel de grado 3 es el clasificador que presenta mayor Sensibilidad haciendo que sea una buena opción de implementación; Sin embargo, se compromete la especificidad de manera considerable. Por esta razón, se opta por el clasificador de K-vecinos cercanos

Tipo de clasificador	Efectividad de entrenamiento(%)	Sensibilidad (%)	Especificidad (%)	Efectividad (%)
SVM con kernel lineal	92,2	83,0	82,6	82,8
SVM con kernel cuadrático	100	96,1	91,1	93,5
SVM con kernel grado 3	99,98	97,7	90,9	94,2
SVM con kernel RBF	100	88,3	100	94,3
Red neuronal 10-10-1	98,2	87,9	82,6	85,2
Red neuronal 10-10-10-1	94,1	93,9	94,2	94,1
Red neuronal 10-10-10-10-1	91,9	87,9	95,7	91,9
k-vecinos cercanos k=1	100	96,9	93,1	94,9
k-vecinos cercanos k=2	100	96,1	92,7	94,3
k-vecinos cercanos k=5	88,4	79,5	76,8	78,1

Tabla 6. Efectividad en el entrenamiento, sensibilidad, especificidad, efectividad promedio para distintos clasificadores utilizando la base de datos ampliada.

En la Figura 4.28 se puede ver el comportamiento del error en la clasificación para las muestras de entrenamiento y prueba que tiende a aumentar con las primeras muestras y a estabilizarse a partir de $k=20$ teniendo un comportamiento oscilatorio.

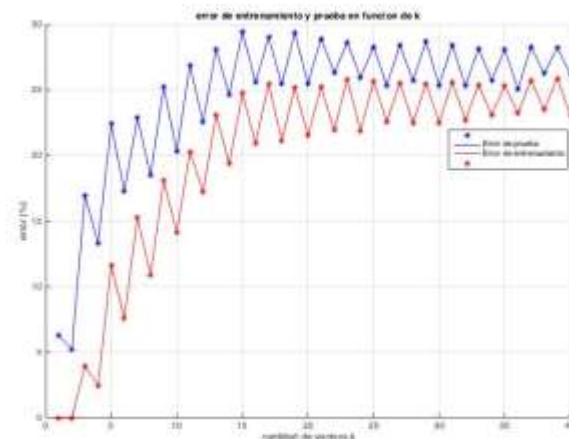


Figura. 4.28. Error de entrenamiento (rojo) y de prueba(azul) en función de la cantidad de vecinos (k).

Para la base de datos original, los clasificadores SVM con kernel lineal y k-vecinos cercanos de $k=5$ siguen siendo los clasificadores con los peores resultados. Además de las redes neuronales, los demás clasificadores discriminaron de forma adecuada entre las dos clases seleccionadas, discriminando correctamente todas las imágenes. En lo respectivo a las redes neuronales, ninguna clasificó de forma correcta todos los datos. Por lo contrario, la red con peor desempeño fue la topología más compleja (Red neuronal 10-10-10-10-1) haciéndose posible concluir que este tipo de clasificador no es el adecuado para el problema de clasificación de lesiones cutáneas.

Tipo de clasificador	Sensibilidad (%)	Especificidad (%)	Efectividad (%)
SVM con kernel lineal	93,9	91,3	92,6
SVM con kernel cuadrático	100	100	100
SVM con kernel grado 3	100	100	100
SVM con kernel RBF	100	100	100
Red neuronal 10-10-1	100	99	99,5
Red neuronal 10-10-10-1	100	99	99,5
Red neuronal 10-10-10-10-1	98,5	97,1	97,8
k-vecinos cercanos k=1	100	100	100
k-vecinos cercanos k=2	100	100	100
k-vecinos cercanos k=5	100	85,5	93

Tabla 7. Sensibilidad, especificidad y efectividad para la base de datos original con los clasificadores entrenados con la base de datos ampliada.

La imagen más difícil de clasificar fue la Figura. 4.29 ya que tres clasificadores (SVM con kernel lineal, Red neuronal 10-10-10-1 y k-vecinos cercanos k=5) no pudieron reconocerla de forma correcta, dado que la textura de este lunar hace que parezca una lesión maligna y los lunares de la base de datos que pertenecen al mismo tipo no son lo suficientemente parecidos para que los sistemas nombrados anteriormente reconozcan el patrón.



Figura. 4.29. Lunar más difícil de clasificar (benigno)

Para establecer una comparación con sistemas anteriores, se obtienen los datos de sensibilidad, especificidad y efectividad de sistemas propuestos en la bibliografía mostrados en la Tabla. 8. Alcon, Cavalcanti y Maryam Ramezani *et al.* proponen sistemas de clasificación basados en el criterio del ABCD para imágenes macroscópicas de lesiones cutáneas tomadas con una cámara sencilla. El sistema propuesto está basado en el mismo principio del ABCD para imágenes macroscópicas utilizando la misma base de datos que Alcon y Cavalcanti. Sin embargo, a partir de las características propuestas y modificaciones en el procesamiento se obtienen mejoras notables en los resultados con respecto a estos dos estudios. Por otro lado, Cristian Ocampo *et al.*, para su tesis de maestría, propone un sistema orientado a imágenes dermatoscópicas⁵ para la ayuda del diagnóstico del especialista inexperto a la hora de utilizar un dermatoscópio. Aunque el desempeño general de su sistema propuesto es mayor, se debe tener en cuenta que reconocer patrones a partir de las imágenes dermatoscópicas es más sencillo que utilizando una imagen macroscópica de la lesión. Además, en el sistema propuesto se tiene un mayor valor de sensibilidad, el cuál es el parámetro más importante para este tipo de sistema.

	Sensibilidad (%)	Especificidad (%)	Efectividad (%)
Sistema propuesto	96,9	93,1	94,9
Alcon <i>et al.</i>	94,4	68,9	80,6
Cavalcanti <i>et al.</i>	92,56	89,16	91,55
Cristian Ocampo <i>et al.</i>	90,6	100	95,2
Maryam Ramezani <i>et al.</i>	82,2	77,0	86,9

Tabla 8. Comparación de las medidas de desempeño con las de trabajos anteriores (Alcon *et al.*(2009), Cavalcanti *et al.*(2011), Cristian Ocampo *et al.*(2011) y Maryam Ramezani *et al.* (2014).

⁵ Imágenes tomadas a partir del dermatoscópio, que es un dispositivo que aumenta la dimensión de la lesión, ofreciendo la visualización de estructuras relevantes con un elevado nivel de detalle.

6 Conclusiones y recomendaciones

- El clasificador con mejor desempeño es el K-vecinos cercanos de $k=1$, ya que solo se hace comparación con el vecino más cercano. Sin embargo, la mayor sensibilidad, que es el parámetro más importante a tener en cuenta; ya que si se reduce se puede poner en riesgo al paciente, la da el clasificador SVM con kernel de grado 3, Pero se compromete la especificidad de manera sustancial; optándose por el primer clasificador mencionado para la implementación.
- Conforme aumenta el valor de k para el clasificador de K- vecinos cercanos disminuye la efectividad, ya que, al tomar una porción mayor de muestras para la comparación, se obtienen más de la clase a la que no pertenece la muestra evaluada, generando una clasificación errada.
- Los clasificadores con menor desempeño fueron el SVM con kernel lineal y K- vecinos cercanos de $k=5$. Por un lado, que el clasificador de kernel lineal de un error elevado permite concluir que los datos no son linealmente separables, haciendo que no haya un hiperplano que clasifique de forma adecuada los resultados. Por el otro lado, se concluye que los datos entre clases están bastante juntos ya que el error al aumentar la cantidad de vecinos ' k ' aumenta considerablemente.
- La red neuronal, aunque no es el clasificador con más bajo desempeño de los probados, no brinda resultados lo suficiente buenos comparados con los clasificadores SVM y K- vecinos cercanos. Por el contrario, la topología más compleja generó unos resultados deficientes en comparación de las demás para la base de datos original.
- Para el entrenamiento del sistema se recomienda utilizar una base de datos actualizada del lugar donde se esté implementando, sea un hospital o lugar específico, ya que de esta forma la clasificación se dará de forma más acertada y confiable.
- El sistema no está diseñado para funcionar en una imagen con alta densidad de vellos para que funcione, habría que añadir un sistema de detección de vellos (se implementó según [8] pero el resultado no coincidió), en el Pre-Procesamiento, que funcione de forma adecuada, lo cual se deja para trabajos futuros. Para lo que sí está diseñado, es para tratar con condiciones de iluminación poco controladas y sus efectos en la curvatura de la piel haciendo que se generen sombras.
- El código implementado en Python, utilizando la librería de código abierto OpenCV, cumple con los objetivos específicos, ya que⁶:
 - 1) Se obtuvo y etiquetó cada imagen de la base de datos (66 muestras de lesiones malignas y 104 benignas).
 - 2) Se diseñaron 70 características basadas en el criterio del ABCD de la dermatología.
 - 3) Se entrenaron 9 clasificadores, entre ellos varias topologías de SVM, Red Neuronal y K-vecinos cercanos (K-nearest neighbor).
 - 4) Se evaluaron las efectividades de entrenamiento, prueba, sensibilidad y especificidad utilizando Cross-Validation para los distintos clasificadores.
 - 5) Se comparó la efectividad, sensibilidad y especificidad con los estudios hechos por Alcon *et al.*(2009), Cavalcanti *et al.*(2011), Cristian Ocampo *et al.*(2009) y Maryam Ramezani *et al* (2011).

Con lo anterior, se cumple el objetivo general de Diseñar y evaluar un sistema de clasificación de imágenes macroscópicas de lunares que requieran seguimiento dermatológico prioritario.

⁶ Cada valor de la enumeración equivale al objetivo específico que se cumplió.

- Fue indispensable la ayuda de médicos especializados en dermatología para la capacitación en conceptos dermatológicos y posterior validación de los resultados obtenidos.
- El lunar más difícil de clasificar pertenece al tipo de lunar benigno que presenta mayores patrones de malignidad tales como textura y bordes pronunciados (nevo melanocítico).
- Ya que el índice de desempeño de un médico dermatólogo experto se encuentra en el intervalo (75-84)% [8]; el sistema propuesto supera este desempeño, haciendo que sea una herramienta confiable.
- Se concluye que el sistema funciona como herramienta de control del dermatólogo para el paciente, pero nunca como diagnóstico directo.
- Las mejoras efectuadas en las características de [2] y adición de nuevas (52 de Cavalcanti *et al.*, 70 del trabajo propuesto) hacen que haya una mejora sustancial en los resultados obtenidos.

7 Bibliografía

- [1] J. F. Alcón *et al.*, “for Inspection of Pigmented Skin Lesions and Melanoma Diagnosis,” vol. 3, no. 1, pp. 14–25, 2009.
- [2] P. G. Cavalcanti, J. Scharcanski, L. E. Di Persia, and D. H. Milone, “An ICA-based method for the segmentation of pigmented skin lesions in macroscopic images,” *Proc. Annu. Int. Conf. IEEE Eng. Med. Biol. Soc. EMBS*, pp. 5993–5996, 2011.
- [3] E. Kim and X. Huang, “Color Medical Image Analysis,” vol. 6, pp. 1–13, 2013.
- [4] M. Ramezani, A. Karimian, and P. Moallem, “Automatic Detection of Malignant Melanoma using Macroscopic Images,” vol. 4, no. 4, pp. 281–290, 2014.
- [5] P. G. Cavalcanti, J. Scharcanski, and G. V. G. Baranoski, “A two-stage approach for discriminating melanocytic skin lesions using standard cameras,” *Expert Syst. Appl.*, vol. 40, no. 10, pp. 4054–4064, 2013.
- [6] ¿Cuáles son las estadística principales del cáncer de piel de tipo melanoma?, [Online]. Available: <https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/acerca/estadisticas-clave.html>
- [7] Pardo, C. Cendales, R. (2015). *Incidencia, mortalidad y prevalencia de Cáncer en Colombia 2007-2011*. Instituto Nacional De Cancerologia (Vol. 1).
- [8] C. Felipe and O. Bland, “Herramienta Soporte al Diagnóstico del Melanoma usando Imágenes Dermatoscópicas,” 2011.
- [9] Estadística y Machine Learning Available: https://rstudio-pubs-static.s3.amazonaws.com/293405_4029f1f23f834b7195189d5504a436b2.html
- [10] Redes Neuronales Available: <http://avellano.fis.usal.es/~lalonso/RNA/index.htm>
- [11] Bishop, Christopher (2008) *Pattern Recognition and Machine Learning*. Springer Verlag. ISBN=978-0-3873-1073-2.
- [12] Convolucion Available: https://www.uniovi.es/computum/laboratorios_web/laborat07c_convolucion/lab07c_convolucion.html
- [13] Ries LAG, et al, eds. SEER Cancer Statistics Review, 1975-2000. Bethesda, MD: National Cancer Institute; 2003: Tables XVI-1-9.
- [14] Johnston SC, Rothwell PM, Nguyen-Huynh MN, *et al.* (enero de 2007). «Validation and refinement of scores to predict very early stroke risk after transient ischaemic attack». *Lancet* **369** (9558): 283-92.
- [15] J. Quiroga, “Proc. De imágenes: Conceptos básicos” 2016” Available: <https://goo.gl/JckqaZ>
- [16] R.GonzalesandR.Woods, *Digital ImageProcessing*, 3rded.PearsonEducationInternational,2014.
- [17] D.Forsyth, *Computer Vision:Amodernaproach*. NewYersey,USA:PrenticeHall,2003.
- [18] 2007 Skin Cancer Facts, [Online]. Available: <http://www.skincancer.org/skincancer-facts.php>, Skin Cancer Foundation, Tech. Rep.
- [19] Cancer Facts and Figures 2008,[Online].Available: <http://www.cancer.org/downloads/STT/2008CAFFfinalsecured.pdf>, Tech. Rep.
- [20] Dermnet Skin Disease Image Atlas, [Online]. Available: www.dermnet.com
- [21] Melanoma Project., [Online]. Available: <http://www.bionorth.org.il/BioNorth/SendFile.asp7GID=446>
- [22] Melanoma Symptoms, [Online]. Available: <http://www.cancerhelp.org/help/default.asp?page=3009>, National Institute for Health and Clinical Excellence, Tech. Rep.
- [23] Skin Cancer: Basal Cell Carcinoma, Squamous Cell Carcinoma,and Malignant Melanoma, [Online]. Available: <http://www.clevelandclinic.org/health/health-info/docs/1800/1852.asp?index=8090>, Cleveland Clinic Center for Consumer Health Information, Tech. Rep.
- [24] Who is at Risk of Melanoma, [Online]. Available: <http://www.dermnetnz.org/lesions/melanoma.html>, New Zealand Dermatological Society Incorporated, Tech. Rep.

- [25] Lesion image. Available:
http://3.bp.blogspot.com/qQ9NPfJU4bs/Tz65C_hQ9SI/AAAAAAAAAGo/iXT1fADydiE/s1600/q.jpeg
- [26] Lesion image. Available:
<http://www.dermis.net/bilder/CD099/550px/img0084.jpg>

8 Anexos

8.1 Código en Python del trabajo de grado

<https://www.dropbox.com/s/uydqzyc0dm0e640/ProyectoGrado.py?dl=0>

8.2 Base de datos de características (Python)

<https://www.dropbox.com/s/vev8wvgo890u322/benignosPY.npy?dl=0>

<https://www.dropbox.com/s/1bmt9z3yw5ill5v/malignosPY.npy?dl=0>

8.3 Base de datos de características ampliada y sus etiquetas (Matlab)

<https://www.dropbox.com/s/s3rj0o8lukym1pb/datosAmpliados.mat?dl=0>

<https://www.dropbox.com/s/2idihuniosdxcyl/labelsAmpliados.mat?dl=0>